

Data Science e Machine Learning na Prática - Introdução e Aplicação na Indústria de Processos

Escola Piloto Prof.Giulio Massarani
{Aula[−1]: "E agora?"}

Afrânio Melo

instagram.com/engepolgrupo
kaggle.com/afrniomelo
afrjr.weebly.com
afraeq@gmail.com

Laboratório de Modelagem, Simulação e Controle de Processos – LMSCP
Laboratório de Engenharia de Polimerização – EngePol
PEQ-COPPE-UFRJ

2020

Final do curso

- Ufa! Finalmente estamos terminando o curso!
- Nesta última aula vamos tirar a mão da massa, deixar os códigos e implementações de lado e responder à simples pergunta: **e agora???**
- Na primeira seção teremos uma apresentação de tudo que não estudamos e considero ser importante na sua jornada de estudo após o curso, dividindo em:
 - Modelos;
 - Metodologias;
 - Bibliotecas;
 - Teoria;
 - Prática.
- Na segunda seção, trataremos de perspectivas mais globais, relacionadas à engenharia de processos e à sociedade como um todo.
- Vamos começar!

Modelos

Como representar os dados

- Modelos são estruturas matemáticas capazes de representar padrões em dados. A depender de que padrões se deseja aprender, diversos modelos podem ser utilizados.
- Estudamos ao longo do curso quatro dos modelos mais populares no aprendizado de máquina, capazes de resolver uma grande classe de problemas: **florestas aleatórias, PCA, redes neurais e k-means**.
- No entanto, há muitos outros a explorar! Enumeraremos a seguir vários tipos de modelos, divididos em duas classes: **tradicionais** e de **aprendizado profundo**.

Modelos tradicionais

- **Modelos lineares:** são modelos simples e por isso úteis em várias situações. Costumam ser claros e fornecer resultados interpretáveis. Exemplos são a regressão linear clássica e suas versões regularizadas (ridge, lasso e redes elásticas).
- **Ensembles de árvores:** aprendemos no curso as florestas aleatórias, baseadas no procedimento de *bagging*, em que é tirada a média de várias árvores treinadas em paralelo com subconjuntos distintos. Mas também é muito popular o procedimento de *boosting*, em que as árvores são treinadas sequencialmente e cada uma tenta diminuir o erro da anterior. Exemplos são os modelos AdaBoost e Gradient Boosting.

Modelos tradicionais

- **k-vizinhos mais próximos (k-NN)**: efetuam predições para uma dada observação utilizando as observações do conjunto de treinamento mais similares a ela. Variam em termos da métrica de similaridade empregada (por exemplo, distância euclidiana) e à maneira como se agregam as informações das observações similares para efetuar predições (por meio da média, etc.).
- **Máquinas de vetores suporte (SVM)**: escolhem pontos especiais no conjunto de dados, chamados de *vetores suporte*, que ajudam a definir modelos com certas propriedades geométricas favoráveis (por exemplo, um classificador com máxima margem de separação entre as classes). Para introduzir não-linearidades, utiliza-se uma operação matemática chamada de **truque do kernel**, que efetua uma transformação do espaço original dos dados para um espaço matemático mais conveniente. Confira mais detalhes [neste notebook](#).

Modelos tradicionais

- **Bayes ingênuo:** modelo de classificação que utiliza o teorema de Bayes para calcular probabilidades, ignorando as correlações entre as variáveis (por isso o adjetivo “ingênuo” no nome).
- **Processos gaussianos:** grupo de modelos que utilizam o teorema de Bayes para atribuir probabilidades a todas as funções f possíveis de serem aprendidas, sob a hipótese de que $p(f(x_1), \dots, f(x_n))$ segue uma distribuição gaussiana.

Modelos tradicionais

- **Modelos autoregressivos:** utilizam valores passados (*lags*) das variáveis como predutores. Exemplos são os modelos VAR e ARIMA. Têm muita popularidade em áreas como econometria e processamento de sinais.
- **Computação de reservatório:** classe de redes neurais recorrentes em que apenas a camada de saída é treinada. A camada oculta, também chamada de “reservatório”, é um espaço de estados de grande dimensão constituído por neurônios com pesos fixos e conexões aleatórias que fica responsável pela modelagem das dependências temporais e características dinâmicas. Exemplos são os modelos Echo State Network (ESN) e Liquid State Machines (LSM).

Modelos tradicionais

- **Decomposição cruzada:** efetua modelagem em variáveis latentes e redução de dimensionalidade de maneira semelhante ao PCA, encontrando direções que maximizam a variação conjunta entre duas matrizes \mathbf{X} e \mathbf{Y} . Do ponto de vista matemático, o modelo Partial Least Squares (PLS) funciona maximizando a covariância, enquanto o Canonical Correlation Analysis (CCA) maximiza a correlação.
- **Análise discriminante de Fisher (FDA):** efetua modelagem em variáveis latentes e redução de dimensionalidade gerando um conjunto ortogonal de combinações lineares das variáveis originais que melhor separa classes (categorias).
- **Análise em componentes independentes (ICA):** efetua modelagem em variáveis latentes e redução de dimensionalidade gerando um conjunto de combinações lineares das variáveis originais de modo que a independência estatística entre as combinações seja máxima.

Modelos tradicionais

- **Aprendizado de variedades:** efetua modelagem em variáveis latentes e redução de dimensionalidade não-linear, sob a hipótese de que os dados estão contidos em uma variedade (uma classe de espaços topológicos da teoria matemática) no espaço multidimensional. Exemplos são os modelos Isomap e *t*-SNE.
- **Dicionários esparsos:** utiliza bases de dimensão maior que o espaço original para criação de uma representação esparsa dos dados, levando a uma boa captura de correlações de ordem superior.

Modelos tradicionais

- **Modelos baseados em densidade:** modelos de clusterização em que os clusters são definidos como regiões contínuas de alta densidade de pontos separadas por regiões de baixa densidade. O modelo mais popular do tipo é o DBSCAN.
- **Clusterização hierárquica:** modelos em que os clusters são organizados em grupos hierárquicos com ordenação bem definida (chegamos a utilizar essa metodologia para agrupar variáveis de acordo com as correlações entre elas, na Aula 1).
- **Misturas gaussianas:** assumem que as amostras foram geradas a partir de uma mistura de várias distribuições gaussianas cujos parâmetros são desconhecidos. O objetivo da modelagem é encontrar esses parâmetros e os pesos que determinam a influência de cada gaussiana na mistura.

Modelos tradicionais

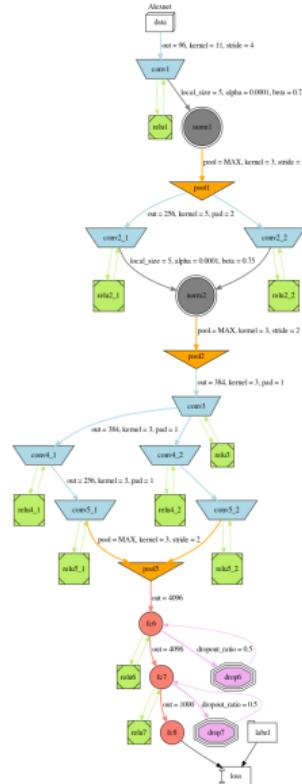
Dicas

- Leia o guia do usuário do scikit-learn. Ao final da leitura você terá tido uma exposição aos modelos tradicionais com bom balanço entre teoria e prática.
- Para cada modelo que você estudar no guia do scikit-learn, procure recursos adicionais na internet, como notebooks do Kaggle, posts de blogs, vídeos no YouTube, cursos MOOC, capítulos de livros, etc., para consolidar o conhecimento.

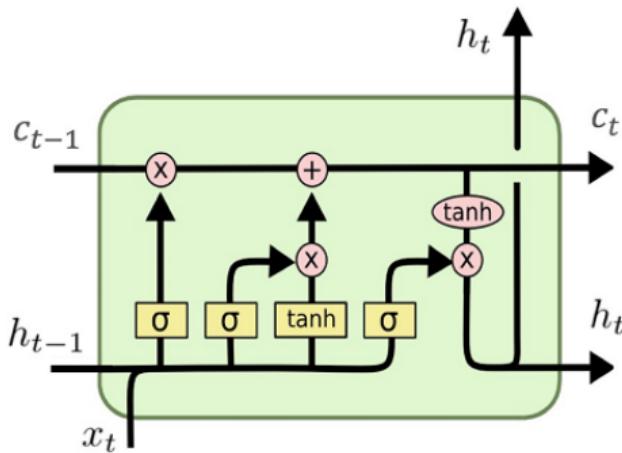
Aprendizado profundo

Arquiteturas

- Modelos de aprendizado profundo podem variar muito de acordo com as arquiteturas das redes!
- Aprendemos no curso as linhas gerais para montagem de arquiteturas convolucionais.
- Uma boa frente de estudo é analisar as diferentes arquiteturas propostas ao longo dos últimos anos, como LeNet-5, AlexNet (representada na figura ao lado), GoogleNet, VGGNet, ResNet, Xception, SENet, etc.
- Muitas dessas arquiteturas estão disponíveis para uso nas bibliotecas (por exemplo, no módulo `keras.applications`).



Aprendizado profundo



LSTM
(Long-Short Term Memory)

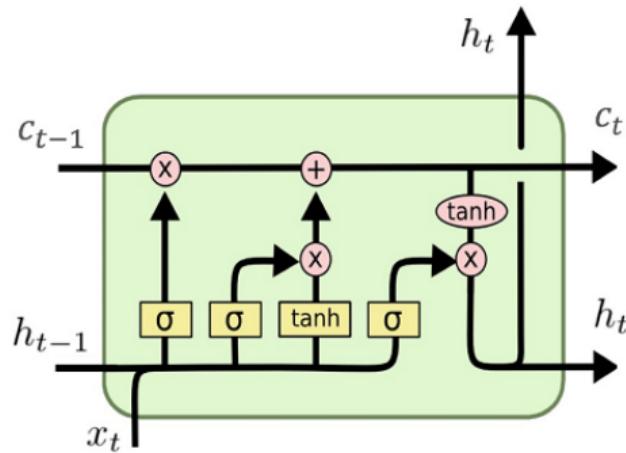
Redes recurrentes

- Modelos recorrentes são aqueles em que o sinal pode ser retroalimentado (ou seja, voltar da saída para a entrada).
- São úteis para modelar dados sequenciais e dinâmica.
- Redes recorrentes são difíceis de treinar por conta do problema do desaparecimento do gradiente, particularmente desafiador no aprendizado de dependências de longo prazo.
- No aprendizado profundo, uma arquitetura muito usada para atenuar esse problema é a Long Short-Term Memory (LSTM).

Aprendizado profundo

Redes recorrentes - LSTM

- Ao lado, temos a representação de uma célula da rede LSTM, responsável por processar um elemento x_t da sequência e fornecer uma saída h_t .
- A célula usa informações do elemento anterior por meio dos sinais h_{t-1} (a própria saída anterior) e c_{t-1} , um sinal responsável por “carregar” memórias de longo prazo.
- A extensão com que a rede carrega as informações ou as esquece no sinal c é determinada pelos pesos das operações efetuadas na célula, ajustados durante o aprendizado.
- Para entender os detalhes das operações, recomendo [esta página](#).



LSTM
(Long-Short Term Memory)

Aprendizado profundo

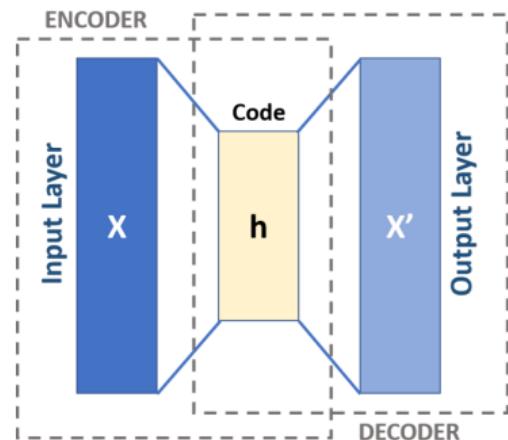
Redes recorrentes - LSTM

- As redes LSTM são populares na área de aprendizado profundo, mas muito da sua aplicabilidade é contestada, em especial para problemas complicados como séries temporais ruidosas.
- Nos próprios exemplos oficiais do [keras](#) e [tensor-flow](#), os resultados demonstrados não são muito bons.
- Cheque [esta](#), [esta](#), [esta](#), [esta](#), [esta](#), [esta](#) ou [esta](#) referências para discussões interessantes a respeito.

Aprendizado profundo

Aprendizado de representação - Autocodificadores

- Autocodificadores são redes que têm como objetivo reproduzir na saída, sob certas restrições, os dados alimentados na entrada.
- A utilidade da metodologia vem da natureza das restrições. Por exemplo, se a camada oculta têm menos neurônios que a entrada, a rede será obrigada a representar os dados em um espaço latente de menor dimensão (chamado de *código*), de maneira semelhante ao procedimento efetuado pelo PCA.
- Para mais detalhes, confira CHARTE *et al.* (2020)^[1].
- Para uma interessante visualização dos dígitos MNIST em uma representação bidimensional de um autocodificador, recomendo [esta página](#).



[1] David Charte *et al.* "An analysis on the use of autoencoders for representation learning: Fundamentals, learning task case studies, explainability and challenges". Em: *Neurocomputing* 404 (set. de 2020), pp. 93-107. DOI: [10.1016/j.neucom.2020.04.057](https://doi.org/10.1016/j.neucom.2020.04.057).

Aprendizado profundo



Aprendizado generativo - GAN's

- O objetivo do aprendizado generativo é gerar novas observações que sejam semelhantes às fornecidas no conjunto de treinamento.
- O modelo mais utilizado na área são as redes generativas adversariais (GAN's, da sigla em inglês), propostas por GOODFELLOW *et al.* (2014)^[2].
- Nas GAN's, duas redes, a geradora e a discriminante, são treinadas simultaneamente em um processo de competição. A geradora tenta transformar ruído aleatório em observações convincentes, enquanto a discriminante tenta distinguir as observações reais das falsas.
- Se o treinamento for bem-sucedido, a rede geradora será capaz de criar observações que enganem perfeitamente a discriminante.

[2] Ian J. Goodfellow *et al.* "Generative Adversarial Networks". Em: *arXiv:1406.2661 [cs, stat]* (jun. de 2014). URL: <http://arxiv.org/abs/1406.2661>.

Aprendizado profundo



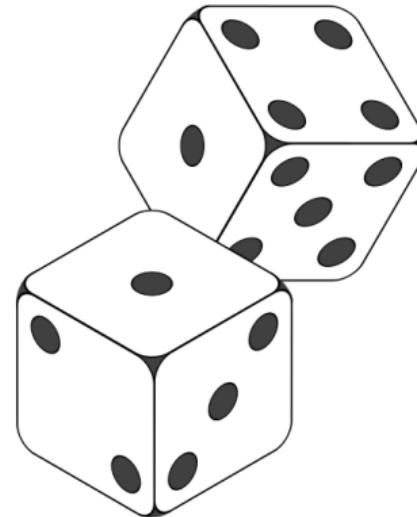
Aprendizado generativo - GAN's

- Uma página muito interessante para aprender mais sobre as GAN's e visualizá-las de maneira interativa é o [GANLab](#).
- As GAN's vêm alcançando sucessos notáveis em várias áreas, em especial na geração de imagens e vídeos (é a principal tecnologia por trás dos deepfakes, por exemplo).
- A criança ao lado não existe. Foi imaginada por uma GAN (confira mais exemplos [nesta página](#)).

Aprendizado profundo

Modelos probabilísticos

- Modelos probabilísticos são aqueles que possuem quantificação de incerteza em sua estrutura.
- Uma tendência dos últimos anos é a incorporação do formalismo probabilístico a modelos de aprendizado profundo, o que pode ser essencial para aumentar sua aplicabilidade a problemas da indústria de processos, em que os dados são particularmente ruidosos.
- Exemplos de modelos são as redes bayesianas e autocodificadores variacionais.
- Para mais detalhes, confira MASEGOSA et al. (2019)^[3].



[3] Andrés R. Masegosa et al. "Probabilistic Models with Deep Neural Networks". Em: arXiv:1908.03442 [cs, math, stat] (out. de 2019). URL: <http://arxiv.org/abs/1908.03442>.

Metodologias

- Além dos modelos, é importante dominar também uma variedade de técnicas e metodologias de aprendizado.
- Aqui falaremos de:
 - Pré-processamento;
 - Processamento de linguagem natural;
 - Aprendizado online;
 - AutoML;
 - Aprendizado por reforço.

Pré-processamento



Limpando os dados!

- Utilizamos alguns métodos de pré-processamento no curso, como normalização, preenchimento de valores faltantes, codificação de variáveis categóricas, seleção de variáveis, filtragem de ruído e transformações de potência.
- Mas há vários outros métodos; cada problema que você abordar pode requerer a aplicação de um diferente!
- No próximo slide são listados alguns desses métodos.

Pré-processamento

- **Remoção de outliers:** visa eliminar os pontos que destoem da distribuição predominante dos dados e possam degradar o desempenho do modelo.
- **Introdução de variáveis não-lineares:** ao se pré-processar variáveis aplicando transformações não-lineares, é possível capturar padrões não-lineares mesmo utilizando modelos lineares.
- **Introdução de variáveis dinâmicas:** fizemos isso com a adição de variáveis atrasadas no tempo no caso do PCA, porém existem outras maneiras de fazê-lo, como adicionando variáveis que representem derivadas ou que detalhem datas em distintas granularidades. Isso torna possível a captura de padrões dinâmicos mesmo utilizando modelos estacionários.
- **Alinhamento temporal e estimativa de atraso:** visa corrigir inconsistências em séries temporais devido a atrasos na propagação da informação ao longo dos processos.

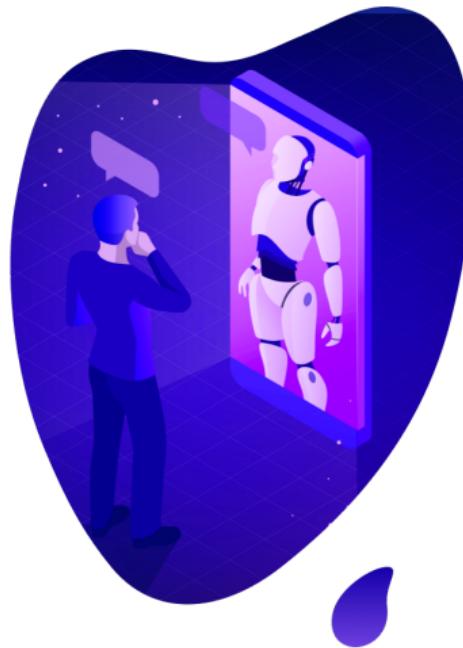
Para mais detalhes, vale a consulta ao artigo de XU *et al.* (2015)^[4].

[4] Shu Xu *et al.* "Data cleaning in the process industries". Em: *Reviews in Chemical Engineering* 31.5 (2015). doi: [10.1515/revce-2015-0022](https://doi.org/10.1515/revce-2015-0022).

Processamento de linguagem natural

Máquinas que nos entendem!

- O processamento de linguagem natural (NLP) tem aplicações em várias áreas: tradução, análise de sentimentos e mesmo na engenharia de processos, como evidenciado no trabalho de THOMPSON (2017)^[5], que propôs metodologias para interpretação de relatórios de operação.



[5] Pedro Thompson. "Interpretação automática de relatórios de operação de equipamentos". Diss. de mestrado. Rio de Janeiro: Pontifícia Universidade Católica do Rio de Janeiro, abr. de 2017. DOI: [10.17771/PUCRio.acad.30732](https://doi.org/10.17771/PUCRio.acad.30732).

Processamento de linguagem natural

- Para efetuar NLP no âmbito do aprendizado de máquina, o primeiro passo é a *tokenização*, ou seja, dividir o texto em várias unidades (caracteres, palavras, etc.), chamadas de *tokens*.
- Após a tokenização, efetua-se a *vetorização*, em que os tokens são transformados em tensores numéricos, a única forma de informação que os modelos entendem.
- Os tipos de vetorização mais comuns são:
 - **One-hot encoding**: um texto é representado como uma matriz em que cada coluna corresponde a um token (cuja dimensionalidade, portanto, é o tamanho do vocabulário). O token associado a uma dada linha (observação) é indicado com o número 1 na coluna correspondente; as demais colunas possuem o valor 0.
 - **Embeddings**: cada token é associado a uma posição em um espaço de dimensão pré-determinada (tipicamente 256, 512 ou 1024). Nesse espaço, as relações semânticas entre as palavras se refletem em relações geométricas. Podemos aproveitar embeddings genéricos disponíveis na internet, prontos para uso, ou aprender embeddings específicos durante o treinamento de cada caso particular.
- Caso você se interesse pelo tema, recomendo que comece aprendendo a usar [os recursos do keras para processamento de linguagem natural](#).

Aprendizado online



Aprendendo continuamente

- No aprendizado online, os modelos são criados de maneira incremental e atualizados constantemente, conforme mais dados vão se tornando disponíveis.
- O paradigma de dados gerados de maneira contínua é chamado de *streaming data*.
- É preciso usar métodos adaptativos para adequar os modelos às contínuas mudanças nas distribuições dos dados (fenômeno conhecido como *concept drift*).
- Sempre há a possibilidade indesejada de modelarmos um comportamento anormal ao confundi-lo com *concept drift*!
- Para mais detalhes, confira GOMES *et al.* (2019)^[6] ou BENCZÚR *et al.* (2018)^[7].

[6] Heitor Murilo Gomes, Jesse Read e Albert Bifet. "Machine learning for streaming data: state of the art, challenges, and opportunities". Em: *ACM SIGKDD Explorations Newsletter* 21.1 (nov. de 2019). doi: [10.1145/3373464.3373470](https://doi.org/10.1145/3373464.3373470).

[7] András A. Benczúr, Levente Kocsis e Róbert Pálavics. "Online Machine Learning in Big Data Streams". Em: *arXiv:1802.05872 [cs, stat]* (fev. de 2018). URL: <http://arxiv.org/abs/1802.05872>.

AutoML

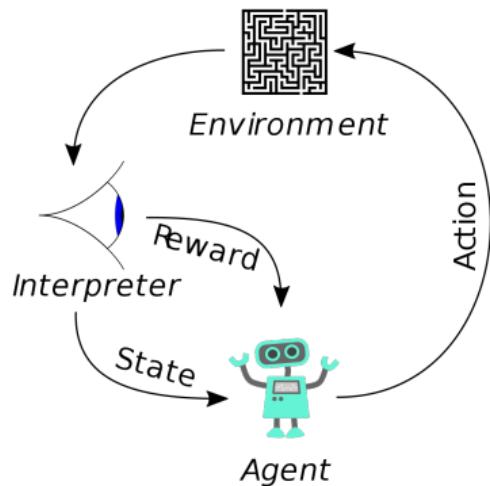
Automatizando o aprendizado

- AutoML se refere a um conjunto de metodologias que busca automatizar todo o fluxo de trabalho de um projeto de aprendizado de máquina, desde o tratamento de dados brutos até a seleção e aplicação do modelo final.
- É uma linha de pesquisa que vem chamando atenção e apesar de (ainda) não alcançar acuráncias comparáveis a especialistas humanos, pode fornecer soluções satisfatórias com baixo custo-benefício ou boas soluções iniciais mesmo para projetos em que se deseja a solução ótima.
- Para mais detalhes, confira HE *et al.* (2020)^[8].



[8] Xin He, Kaiyong Zhao e Xiaowen Chu. "AutoML: A Survey of the State-of-the-Art". Em: *arXiv:1908.00709 [cs, stat]* (jul. de 2020). URL: <http://arxiv.org/abs/1908.00709>.

Aprendizado por reforço



Adestrando a máquina!

- O aprendizado por reforço é uma metodologia de treinamento em que um agente executa ações em um ambiente e decide quais ações tomar a seguir, com base no estado do ambiente e em uma recompensa fornecidos por um interpretador.
- É um cenário parecido com o que se utiliza no adestramento de animais, por exemplo.
- Junto com as abordagens supervisionada e não-supervisionada, constitui uma das três metodologias básicas de treinamento, sendo no entanto menos utilizada em problemas práticos e estando ainda restrita a ambientes de estudo e pesquisa.
- Na indústria de processos, vem sendo investigada principalmente em aplicações de controle, como evidenciado por NIAN et al. (2020)^[9] ou SHIN et al. (2019)^[10].

[9] Rui Nian, Jinfeng Liu e Biao Huang. "A review on reinforcement learning: Introduction and applications in industrial process control". Em: *Computers & Chemical Engineering* 139 (ago. de 2020), p. 106886. DOI: [10.1016/j.compchemeng.2020.106886](https://doi.org/10.1016/j.compchemeng.2020.106886).

[10] Joohyun Shin et al. "Reinforcement Learning – Overview of recent progress and implications for process control". Em: *Computers & Chemical Engineering* 127 (ago. de 2019), pp. 282–294. DOI: [10.1016/j.compchemeng.2019.05.029](https://doi.org/10.1016/j.compchemeng.2019.05.029).

Bibliotecas

Construindo uma caixa de ferramentas!

- As ferramentas de ciência de dados e aprendizado de máquina no Python estão disponíveis tipicamente na forma de bibliotecas.
- No curso utilizamos diversas bibliotecas como [NumPy](#), [Matplotlib](#), [pandas](#), [scikit-learn](#), [keras](#), [Optuna](#), entre outras.
- No próximo slide há uma lista com mais algumas que podem se mostrar úteis na sua futura jornada.

Bibliotecas

- **Estatística:** [statsmodels](#); [Stan](#); [PyMC3](#); [pomegranate](#).
- **Pré-processamento/análise exploratória:** [pandas-profiling](#); [Sweetviz](#); [dataprep](#); [PyOD](#); [Dora](#); [Data Retriever](#).
- **Visualização:** [plotly](#); [Bokeh](#).
- **Explicações/interpretações:** [SHAP](#); [ELI5](#).
- **Ensembles de árvores:** [LightGBM](#); [XGBoost](#).
- **Aprendizado profundo:** [TensorFlow](#); [PyTorch](#); [fastai](#).
- **GAN's:** [Keras-GAN](#); [PyTorch-GAN](#); [TorchGAN](#); [TensorFlow-GAN](#); [pygan](#).
- **Aprendizado online:** [river](#); [stream-learn](#).
- **AutoML:** [auto-sklearn](#); [AutoKeras](#); [TPOT](#); [AutoGluon](#); [NNI](#).
- **Aprendizado por reforço:** [gym](#); [bsuite](#); [Stable-Baselines](#); [Acme](#); [Keras-RL2](#).
- **Séries temporais:** [scikit-time](#); [fireTS](#); [tslearn](#); [tsfresh](#); [STUMPY](#); [Prophet](#).
- **Data apps:** [Voilà](#); [Streamlit](#); [Dash](#).
- **Computação de alto desempenho/Big data:** [Dask](#); [Vaex](#); [Modin](#); [Ray](#); [Joblib](#), [ipyparallel](#); [Numba](#); [Cython](#); [Apache Hadoop](#); [Apache Spark](#).
- **Computação científica:** [SciPy](#); [SymPy](#); [diffeqpy](#); [PyDSTool](#); [NLopt](#); [Pyomo](#); [nevergrad](#); [Ax](#).
- **Engenharia de processos:** [GEKKO](#); [IDAES](#); [BioSTEAM](#); [python-control](#); [Cantera](#); [chemicals](#); [FluidDyn](#); [chemicals](#); [thermo](#); [fluids](#); [ht](#); [fpi](#).

Teoria

Construindo uma base sólida

- Outro ponto de estudo importante, muitas vezes negligenciado, é a teoria!
- É possível obter uma boa base teórica por meio da leitura dos manuais das bibliotecas, mas muitas vezes é necessário aprofundar utilizando materiais adicionais.
- Nos próximos slides recomendo alguns desses materiais, como livros, cursos, etc.

Livros

Ciência de dados

- **VANDERPLAS (2016) - Python Data Science Handbook - Essential Tools for Working with Data:** uma descrição detalhada do principal que você precisa saber para se tornar um praticante de ciência de dados no Python: Jupyter, NumPy, Pandas, Matplotlib e scikit-learn.
- **SKIENA (2017) - The Data Science Design Manual:** enquanto o livro anterior tem um caráter instrumental, este é mais conceitual. Os dois juntos constituem um excelente combo.
- **GRUS (2019) - Data Science from Scratch - First Principles with Python:** aqui, os conceitos e ferramentas da ciência de dados são ilustrados com implementações em Python puro, sem o uso de nenhuma biblioteca em que as implementações já estejam prontas. A primeira edição possui tradução em português.
- **MCKINNEY (2017) - Python for Data Analysis - Data Wrangling with Pandas, NumPy, and IPython:** escrito pelo autor da biblioteca pandas. Vocês podem imaginar qual é o foco.

Livros

Aprendizado de máquina - livros práticos

- **GERÓN (2019) - Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow - Concepts, Tools, and Techniques to Build Intelligent Systems:** o meu favorito. Consegue ser prático e claro sem perder o rigor e abrangência. Se for escolher apenas um livro da lista, leia este. A primeira edição tem tradução em português, mas sua metade final está desatualizada porque usa a versão 1 da biblioteca TensorFlow.
- **HARRISON (2019) - Machine Learning Pocket Reference: Working with Structured Data:** livro curto com o objetivo de ser uma referência rápida para consulta aos principais procedimentos a se usar na aplicação de modelos tradicionais de aprendizado.
- **CHOLLET (2017) - Deep Learning with Python:** introdução ao aprendizado profundo escrita pelo autor da biblioteca Keras. Uma versão enxuta do texto em formato de notebooks pode ser acessado gratuitamente [neste endereço](#).
- **STEVENS, ANTIGA e VIEHMANN (2020) - Deep Learning with PyTorch: Build, train, and tune neural networks using Python tools:** introdução ao aprendizado profundo, escrito pelos autores da biblioteca PyTorch.
- **HOWARD e GUGGER (2020) - Deep Learning for Coders with Fastai and PyTorch: AI Applications Without a PhD:** introdução ao aprendizado profundo, escrito pelo autor da biblioteca fastai. O livro em formato de notebooks pode ser acessado gratuitamente [neste endereço](#).

Livros

Aprendizado de máquina - livros teóricos

- **RUSSEL E NORVIG (2020) - Artificial Intelligence: A Modern Approach:** este livro trata de inteligência artificial de forma bem ampla. Apenas a quinta das sete seções é dedicada ao aprendizado de máquina.
- **ABU-MOSTAFA (2012) - Learning From Data: A Short Course:** introduz de forma concisa, elegante e sólida os fundamentos teóricos dos modelos tradicionais de aprendizado.
- **HASTIE, TIBSHIRANI E FRIEDMAN (2009) - The Elements of Statistical Learning: Data Mining, Inference and Prediction:** de um ponto de vista estatístico, trata com profundidade os conceitos teóricos por trás dos algoritmos e modelos tradicionais de aprendizado. O PDF pode ser acessado gratuitamente [aqui](#).
- **MARSLAND (2014) - Machine Learning, An Algorithmic Perspective:** um meio termo entre o teórico e o prático. O foco está no funcionamento dos algoritmos, que são ilustrados com códigos usando apenas o NumPy, sem aplicação de bibliotecas específicas de aprendizado.
- **GOODFELLOW, BENGIO e COURVILLE (2016) - Deep Learning:** escrito pelo inventor das GAN's, este texto sobre aprendizado profundo está disponível gratuitamente [neste endereço](#).
- **AGGARWAL (2018) - Neural Networks and Deep Learning: A Textbook:** outro excelente texto com abordagem teórica sobre aprendizado profundo.

Livros

Aprendizado de máquina - miscelânea de tópicos

- PANDEY *et al.* (2020) - Machine Learning in the Oil and Gas Industry: Including Geosciences, Reservoir Engineering, and Production Engineering with Python.
- SUTTON e BARTO (2018) - Reinforcement Learning: An Introduction - pode ser acessado gratuitamente [aqui](#).
- DUERR, SICK e MURINA (2020) - Probabilistic Deep Learning: With Python, Keras and TensorFlow Probability.
- FOSTER (2019) - Generative Deep Learning: Teaching Machines to Paint, Write, Compose, and Play.
- KUHN e JOHNSON (2019) - Feature Engineering and Selection: A Practical Approach for Predictive Models.
- NIELSEN (2019) - Practical Time Series Analysis: Prediction with Statistics and Machine Learning.
- MEHROTRA, MOHAN e HUANG (2017) - Anomaly Detection Principles and Algorithms.
- GARCÍA, LUENGO e HERRERA (2014) - Data Preprocessing in Data Mining.
- AGGARWAL (2017) - Outlier Analysis.

Livros

Python

- **LUBANOVIC (2019) - Introducing Python - Modern Computing in Simple Packages:** minha introdução favorita ao Python. Organizada, clara, concisa e moderna.
- **JOHANSSON (2018) - Numerical Python: Scientific Computing and Data Science Applications with Numpy, SciPy and Matplotlib:** o foco aqui é a aplicação do Python para resolução de problemas numéricos. Trata muito bem de conceitos básicos e avançados em várias áreas de aplicação.
- **ROSSANT (2018) - IPython Interactive Computing and Visualization Cookbook:** este livro pode levar sua habilidade prática em Python a um próximo nível. Contém excelentes exemplos de aplicações do Python nas áreas de computação científica e ciência de dados. Boa parte do livro está disponível gratuitamente [neste endereço](#).

Livros

Matemática

- **DEISENROTH (2020) - Mathematics for Machine Learning:** trata dos principais tópicos da matemática aplicáveis ao aprendizado de máquina, como álgebra linear, cálculo vetorial, estatística e otimização. Está disponível gratuitamente [neste endereço](#).
- **AGGARWAL (2020) - Linear Algebra and Optimization for Machine Learning: A Textbook:** como o anterior, também trata de aplicações da matemática a algoritmos de aprendizado, com foco maior em metodologias de otimização.
- **LIMA (2018) - Álgebra Linear:** meu livro de álgebra linear favorito. Claro, conciso, consistente e elegante.
- **PINHEIRO et al. (2012) - Probabilidade e Estatística: Quantificando a Incerteza:** um bom livro de probabilidade e estatística em português.
- **SCHWAAB e PINTO (2007) - Análise de Dados Experimentais I. Fundamentos de Estatística e Estimação de Parâmetros:** trata de procedimentos de estimativa de parâmetros utilizando o formalismo estatístico, aspecto muitas vezes negligenciado na prática.

Cursos

- [PythonProgramming.net](#): aqui há cursos sobre muitos assuntos envolvendo Python, como Big Data para bolsa de valores, aprendizado por reforço, robótica, carros autônomos e até mesmo computação quântica. Alguns vídeos têm tradução para o português.
- [fast.ai](#): aqui há cursos sobre aprendizado profundo, processamento de linguagem natural, álgebra linear computacional e ética de dados.
- [freeCodeCamp](#): ONG que oferece cursos e emissão gratuita de certificados. Destaque para o [canal do YouTube](#) que possui milhares de horas de aulas.
- [Didática Tech](#): aqui há alguns cursos em português sobre programação, ciência de dados e aprendizado de máquina.
- [Google AI](#): possui cursos sobre vários assuntos como clusterização, sistemas de recomendação, engenharia de características, etc.
- [Microsoft AI School](#): possui cursos sobre vários assuntos como sistemas autônomos, inteligência artificial conversacional, etc.
- [AWS Training and Certification](#): recursos utilizados pela Amazon para treinar seus desenvolvedores e cientistas de dados, muitos dos quais agora disponibilizados livremente. Destaque para o [canal do YouTube](#) da Machine Learning University.

Cursos

- [Coursera](#): os cursos aqui são livres para assistir, sendo cobrados apenas os certificados. Destaque para o material disponível em [deeplearning.ai](#).
- [edX](#): como o anterior, também possui muitos cursos livres para assistir.
- [MIT OpenCourseWare](#): há cursos disponíveis sobre as mais diversas áreas, incluindo ciência de dados e aprendizado de máquina.
- [Learning From Data](#): curso correspondente ao livro de mesmo nome, oferecido em 2012 na CalTech.
- [CS109 Data Science](#): curso sobre ciência de dados oferecido por dois cientistas da computação e um estatístico em 2015 em Harvard.
- [DS-GA 1008 Deep Learning](#): curso sobre aprendizado profundo oferecido em 2020 na New York University.
- [mlcourse.ai](#): curso aberto sobre aprendizado de máquina usando modelos tradicionais oferecido por vários membros da comunidade.
- [HPC Python Course 2020](#): curso de computação de alto desempenho usando Python.
- [Udacity](#), [Udemy](#), [DataCamp](#), [Dataquest](#), [Codeacademy](#), [Lynda](#), [Data Science Academy](#), [Alura](#), entre outros, oferecem cursos pagos, muitas vezes com preços em conta.

Outros recursos

- [Data Science Cheatsheet](#): arquivo em PDF com um resumo dos principais conceitos da ciência de dados. Outras cheatsheets interessantes podem ser encontradas [aqui](#).
- [Deep Learning Book](#): livro sobre aprendizado profundo em português publicado em formato de blog pela Data Science Academy.
- Há vários canais de YouTube com conteúdos interessantes; vale destacar [StatQuest with Josh Starmer](#) e [3Blue1Brown](#), que possuem alguns vídeos traduzidos para o português ou [Programação Dinâmica](#), [Minerando Dados](#) ou [Amanda Lemette](#), com conteúdo original na nossa língua.
- Podcasts são séries temáticas no formato de áudio, parecidas com programas de rádio. Particularmente, gosto muito do [Lex Fridman Podcast](#). Outras sugestões podem ser conferidas [aqui](#) ou [aqui](#).
- [KDNNuggets](#), [Data Science Central](#) e [Towards Data Science](#) são algumas das várias plataformas de blogs que você pode acompanhar.
- Para se manter em dia com os avanços no campo, vale acompanhar newsletters como [Best of Machine Learning](#) ou páginas como [Papers With Code](#) ou [Arxiv Sanity Preserver](#).

Prática

- Em qualquer atividade, manter a prática constante é essencial para se alcançar a excelência.
- No caso da ciência de dados e aprendizado de máquina, isso significa cultivar uma rotina de implementações e resolução de problemas, preferencialmente relacionados a sua atuação profissional.
- Caso você não tenha acesso a dados em sua empresa ou projeto de pesquisa, existem várias fontes onde procurar, como [Kaggle Datasets](#), [UCI Machine Learning Repository](#), [Google Dataset Search](#), [Mendeley Data](#), [re3data](#), [Awesome Public Datasets](#), etc.
- Os próximos slides têm algumas sugestões de conjuntos de dados relacionados à indústria de processos.

Conjuntos de dados

- [3W Dataset](#): detecção de eventos anormais em poços de petróleo (disponibilizado pela Petrobras).
- [Bosch Production Line Performance](#): detecção de falhas na produção de chocolate.
- [Severstal: Steel Defect Detection](#): detecção de falhas na produção de ferro.
- [VSB Power Line Fault Detection](#): detecção de falhas em linhas elétricas.
- [Condition Monitoring of Hydraulic Systems](#): detecção de falhas em sistemas hidráulicos.
- [Pump Sensor Data](#): detecção de falhas em bombas.
- [Cranfield Multiphase Flow Facility](#): detecção de falhas em um processo de escoamento multifásico.
- [PRONTO](#): detecção de falhas em um processo de escoamento multifásico.
- [PCoE Datasets](#): coleção de conjuntos de dados reunida pela NASA para aplicação de algoritmos de prognóstico.
- [Gas sensor array under dynamic gas mixtures](#): sensores de gás expostos a misturas dinâmicas de etileno e metano em ar ou etileno e CO em ar.
- [Gas sensor array temperature modulation](#): sensores de gás expostos a misturas dinâmicas de CO e ar sintético úmido.

Conjuntos de dados

- [Oil and Gas Authority Data Centre](#): dados diversos disponibilizados pela agência Oil and Gas Authority do Reino Unido. Destaque para a seção [OGA Open Data](#), que contém mais de 130 TB de dados de poços, geofísicos, de campo e de infraestrutura. Repositórios parecidos de outros países podem ser conferidos [aqui](#).
- [Open Industrial Data](#): oferece dados em tempo real de um compressor na plataforma de petróleo Valhall da Aker BP no Mar do Norte. Há intenção de adição de mais fontes de dados.
- [IndPenSim](#): simulação de um sistema de fermentação de penicilina.
- [Data for: Causality validation of Multilevel Flow Modelling](#): simulação dinâmica de um sistema offshore de separação a altas pressões.
- [Industrial Safety and Health Analytics Database](#): relatórios de acidentes em 12 diferentes plantas de uma grande indústria brasileira em 3 diferentes países.
- [Toxic Release Inventory](#): dados da Agência de Proteção Ambiental (EPA) dos EUA sobre liberação de produtos químicos tóxicos de 1987 a 2016.
- [Fertilizers by Product FAO](#): produção, importação e exportação de fertilizantes discriminados com base em sua composição química, relativos a vários países.
- Para mais conjuntos de dados industriais, vale a consulta ao repositório [Awesome Public Industrial Datasets](#). Uma interessante leitura sobre o assunto está disponível [aqui](#).

Dicas

- É fácil se perder em meio a tantos conteúdos recomendados!
- Recomendo que você os analise e escolha alguns para focar de acordo com seus objetivos, preferências e deficiências.
- Organize os estudos priorizando atividades práticas. Aprofunde-se na teoria dos modelos e procedimentos conforme os for utilizando.
- Obs: se você tem dificuldades com o inglês, ainda pode aproveitar muitos dos vídeos do YouTube ativando as legendas automáticas.

Inteligência artificial e engenharia de processos



- Nesta seção, nosso objetivo é:
 - entender como o crescimento dos campos de ciência de dados e aprendizado de máquina e, mais genericamente, da inteligência artificial impactou, impacta e provavelmente impactará o campo da engenharia de processos.
- Esta seção é baseada em um trabalho recente publicado pelo engenheiro químico indiano Venkat Venkatasubramanian^[11].

[11] Venkat Venkatasubramanian. "The promise of artificial intelligence in chemical engineering: Is it here, finally?" Em: *AIChE Journal* 65.2 (2019), pp. 466–478. DOI: [10.1002/aic.16489](https://doi.org/10.1002/aic.16489).

Inteligência artificial e engenharia de processos

As 3 fases da IA na engenharia de processos

- O estudo da inteligência artificial (IA) na engenharia de processos pode ser descrito em três fases:
 - **Fase I:** sistemas especialistas;
 - **Fase II:** redes neurais rasas;
 - **Fase III:** ciência de dados e redes neurais profundas.

Inteligência artificial e engenharia de processos

Fase I: sistemas especialistas (~1983 à ~1995)

- *Sistemas especialistas* são programas de computador que mimetizam o método de resolução de problemas dos seres humanos utilizando conhecimento do domínio acumulado pela experiência humana (possivelmente na forma de *heurísticas*).
- Nesses sistemas, a ordem de execução é separada do conhecimento do domínio. Isso proporciona flexibilidade e a possibilidade de adição de conhecimento de forma incremental.

Inteligência artificial e engenharia de processos

Fase I: sistemas especialistas (~1983 à ~1995)

- **Vantagens:**

- representação e arquitetura intuitivas;
- há explicações plausíveis para as decisões tomadas pelo sistema.

- **Desvantagens:**

- alto custo (dinheiro, tempo e esforço) para implementar, manter e monitorar um sistema especialista confiável;
- dificuldade de escalar o sistema.

- **Algumas aplicações:**

- predição de propriedades termofísicas de misturas complexas de fluidos;
- *design* de catalisadores;
- síntese de processos.

Inteligência artificial e engenharia de processos

Fase II: redes neurais rasas (~1990 à ~2008)

- Nessa fase começa-se a aplicar o aprendizado de máquina. O conhecimento pode passar a vir da máquina aprendendo a partir dos dados e não apenas da experiência humana.
- Tudo começou com o algoritmo de retropropagação do erro para o treinamento das redes neurais, proposto por RUMELHART *et al.* (1986)^[12], que aprendemos no curso.
- O algoritmo fez com que problemas fortemente não-lineares pudessesem ser modelados de forma automática e simples.
- Surgiu então uma imensa quantidade de trabalhos usando redes neurais em várias áreas do conhecimento. Especificamente na área de engenharia de processos, muito se avançou principalmente em termos de modelagem/controle e detecção/diagnóstico de falhas.

[12] David E. Rumelhart, Geoffrey E. Hinton e Ronald J. Williams. "Learning representations by back-propagating errors". Em: *Nature* 323.6088 (1986), pp. 533–536. DOI: [10.1038/323533a0](https://doi.org/10.1038/323533a0).

Inteligência artificial e engenharia de processos

Fase II: redes neurais rasas (~1990 à ~2008)

- Mas, logo depois do começo, as coisas esfriaram e pararam de avançar.
- Problemas mais complexos surgiam e as redes não eram capazes de resolver.
- Suspeita: necessidade de cada vez mais camadas ocultas, além de apenas uma.
- Mas, na época, parecia impossível treinar esse tipo de rede...

Inteligência artificial e engenharia de processos

Falta de impacto nas fases I e II

- Apesar dos avanços citados, nas fases I e II não houve impacto real da inteligência artifical na indústria de processos. Vários foram os motivos:
 - limitação de dados;
 - limitação na capacidade computacional;
 - falta de interesse do mercado, já que abordagens mais tradicionais (MPC, otimização, etc.) evoluíam mais rápido e forneciam resultados mais satisfatórios.
- Não havia o *empurrão da tecnologia* e nem o *puxão do mercado*.

Inteligência artificial e engenharia de processos

Fase III: ciência de dados e aprendizado profundo (~2005 à ~hoje)

- A partir da segunda metade da década de 2000 houve um renascimento do interesse na IA devido aos sucessos das abordagens propostas pela ciência de dados, estudadas no curso, em particular os modelos de aprendizado profundo.

Inteligência artificial e engenharia de processos

As coisas são diferentes na fase III?

- Alguns motivos pelos quais podemos supor que o cenário na fase III é diferente:
 - a tendência da Indústria 4.0, com mais instrumentação e sensores, deve tornar os dados cada vez mais abundantes;
 - a capacidade computacional só faz aumentar (a lei de Moore ainda não falhou!);
 - o interesse do mercado é cada vez maior, por conta do sucesso da IA em outras áreas e pelo fato das abordagens tradicionais (como MPC) já terem fornecido a maior parte dos benefícios de que são capazes, diminuindo a capacidade de evolução adicional;
 - tipicamente, uma tecnologia demora 50 anos para amadurecer, penetrar e provocar um impacto generalizado, desde a descoberta até a adoção final (Aspen Plus e MPC, por exemplo). Isso indica que a IA deve atingir a plenitude do seu impacto na década de 2030.
- Agora parece haver o *empurrão da tecnologia e puxão do mercado!!*

Inteligência artificial e engenharia de processos

Um banho de água fria

- Apesar de haver motivo para animação, também há para desconfiança:
 - ao contrário dos campos de finanças, visão, linguagem, redes sociais, etc., nosso campo não é plenamente Big Data, se considerada a definição apresentada lá no começo do curso;
 - a maioria dos modelos de aprendizado profundo são de difícil interpretação, não permitindo uma análise clara dos motivos de suas tomadas de decisão, tornando-os menos propensos à intuição e interpretação humanas;
 - o aprendizado profundo é, em última análise, um método ineficiente. Uma criança precisa de um ou dois exemplos para aprender a reconhecer, digamos, uma vaca, enquanto um algoritmo de aprendizado profundo precisa treinar milhares de vezes com milhares de vacas;
 - as redes neurais humanas nascem com instintos, intuição, acumulam memória de toda uma vida, etc. As redes artificiais atuais, em geral, começam do zero. Como mimetizar todo o acúmulo de informação que ocorre no cérebro humano?
 - E o grande problema da inteligência artificial: a falta de *consciência* (seria isso bom ou ruim?).

Inteligência artificial e engenharia de processos

Desafios para a evolução da IA na engenharia de processos

- avançar na melhoria da instrumentação industrial, de modo a aumentar a quantidade de dados disponíveis;
- avançar além da abordagem puramente centrada em dados, explorando outros aspectos da IA, como o raciocínio baseado em estruturas e relações simbólicas;
- desenvolvimento de modelos híbridos, baseados tanto em dados quanto no conhecimento tradicional da engenharia de processos (termodinâmica, cinética, fenômenos de transporte, etc.);
- aplicar a IA para o desenvolvimento de *teorias de emergência*, talvez o problema científico mais desafiador do séc XXI, que em tese se solucionado poderia resolver a *questão da natureza da consciência*;
- adaptar o ensino nas universidades para que reflita essa nova classe de conhecimentos.

Ética de dados

- Nesta seção, nosso objetivo é:
 - entender como o crescimento dos campos de ciência de dados e aprendizado de máquina impacta a sociedade de maneiras profundas e como a disciplina de ética de dados torna-se necessária para jogar luz sobre várias questões urgentes e relevantes que vêm surgindo recentemente.
- Esta seção é baseada principalmente nas reflexões propostas pela cientista da computação americana Rachel Thomas, que oferece um [curso de ética de dados](#) na Universidade de São Francisco.



O que é ética?



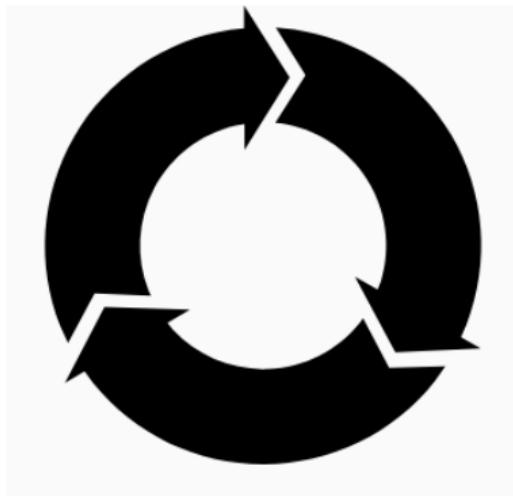
- A ética é o ramo da filosofia que estuda o valor das condutas individuais e sociais.
- Na ética são definidos e sistematizados conceitos como bondade, correção e justiça.
- Estudar ética de dados é importante porque por trás dos algoritmos sempre há programadores e companhias agindo com condutas que geram impactos sociais potencialmente gigantescos!
- A relevância do tema torna-se ainda mais evidente quando se percebe que muitos desses impactos danosos não são resultado direto das intenções dos programadores e sim consequências não planejadas da lógica algorítmica.

Desinformação

- A desinformação sempre existiu, mas modelos de aprendizado de máquina podem ajudar a potencializá-la.
- Via de regra, modelos são designados para maximizar o ganho financeiro de uma companhia. Um exemplo é o algoritmo de recomendação do YouTube, que tem como objetivo maximizar o tempo de tela.
- Se alguém começa a assistir vídeos desinformativos no YouTube, o algoritmo irá enredá-lo em uma teia infundável de vídeos parecidos, criando um ciclo vicioso!
- Além do mais, teóricos da conspiração e outros grupos suscetíveis à desinformação passam mais tempo consumindo vídeos no YouTube do que a média da população, o que faz esse tipo de conteúdo ser privilegiado pelo algoritmo.



Loops de feedback



- Loops de feedback são situações em que os modelos efetuam previsões que influenciam tomadas de decisões no mundo real, o que por sua vez implica em previsões ainda mais pronunciadas no mesmo sentido.
- Usando novamente como exemplo o sistema de recomendações do YouTube, consideremos o problema de vídeos com conteúdo extremista. Quanto mais vídeos do tipo são recomendados, mais pessoas os assistem e desenvolvem pontos de vista extremistas, o que por sua vez aumenta a quantidade de vídeos extremistas sendo produzidos e recomendados!
- Os loops de feedback podem ficar ainda mais críticos quando combinados a *vieses* embutidos nos modelos, como demonstrado a seguir.

- SURESH E GUTAG (2020)^[13] sistematizaram os vários tipos de vieses que podem estar presentes em modelos de aprendizado:
 - **histórico:** inerente à sociedade, podendo existir mesmo com amostragem e engenharia de características perfeitas;
 - **de representação:** quando o conjunto de treinamento não é representativo de toda a população com que se efetuará predições;
 - **de medição:** quando as medições efetuadas para gerar os dados não são apropriadas ou são efetuadas de maneira errada;
 - **de agregação:** quando distintas populações são combinadas de maneira inapropriada, resultando em um modelo que não é capaz de generalizar bem para todas elas;
 - **de avaliação:** quando as amostras usadas para avaliação não são representativas ou as métricas de avaliação não são adequadas;
 - **de implantação:** quando os sistemas são implantados, utilizados ou interpretados de maneira errada ou inapropriada.



[13] Harini Suresh e John V. Guttag. *A Framework for Understanding Unintended Consequences of Machine Learning.* 2020. arXiv: 1901.10002 [cs.LG].

Viés

Turkish - detected▼



English▼

o bir aşçı

she is a cook

o bir mühendis

he is an engineer

o bir doktor

he is a doctor

o bir hemşire

she is a nurse

o evli

she is married

o bekar

he is single

o mutlu

he's happy

o mutsuz

she is unhappy

o çalışkan

he is hard working

o tembel

she is lazy

Machismo presente na estrutura da linguagem natural e modelado em embeddings do sistema de tradução do Google^[14].

[14] Tolga Bolukbasi et al. *Man is to Computer Programmer as Woman is to Homemaker? Debiasing Word Embeddings.* 2016. arXiv: 1607.06520 [cs.CL].

Viés

 **Maureen Rose**
@itsreenchan 

#faceapp is super racist. This is their "spark" aka "hot" filter.



1:00 AM · 25 de abr de 2017 

 1  Veja outros Tweets de Maureen Rose

Racismo em aplicativo. Intenção dos programadores ou consequência de vieses resultantes de um time de desenvolvimento pouco diverso?

Machine Bias

There's software used across the country to predict future criminals. And it's biased against blacks.

by Julia Angwin, Jeff Larson, Surya Mattu and Lauren Kirchner, ProPublica
May 23, 2016

TASER WILL USE POLICE BODY CAMERA VIDEOS “TO ANTICIPATE CRIMINAL ACTIVITY”

Taser is collecting an unprecedented video archive of law enforcement encounters — and it wants to use AI and “deep learning” to predict criminal behavior.

Racismo em sistemas de predição criminal que pode resultar em gravíssimos loops de feedback (fontes [aqui](#) e [aqui](#)).

POLICY & ETHICS | OPINION

Health Care AI Systems Are Biased

We need more diverse data to avoid perpetuating inequality in medicine

Vieses em modelos aplicados a sistemas de saúde também podem ter graves consequências (fonte [aqui](#)).

Privacidade e vigilância



- Várias questões relevantes envolvendo privacidade de dados e vigilância vêm surgindo nos últimos anos:
 - Devemos nos preocupar com a quantidade cada vez maior de dados pessoais que fornecemos a várias empresas?
 - Qual nível de consciência e controle temos sobre dados pessoais que as empresas coletam e mantêm?
 - Extrair lucros de dados obtidos em sua maioria sem plena consciência dos indivíduos é aceitável do ponto de vista ético?
 - Vale a pena sacrificar a privacidade em troca de uma maior segurança proporcionada por mecanismos de vigilância governamental?
 - Que ações devem ser tomadas, a nível individual e coletivo, para lidar com questões de privacidade de dados?
- Algumas dessas reflexões serão retomadas na próxima seção.

Ética de dados - comentários finais

- Sistemas de inteligência artificial que simplesmente maximizam métricas de desempenho preditivo ou econômicas podem ser questionáveis do ponto de vista ético.
- Mesmo que fiquemos restritos à indústria de processos e não trabalhemos diretamente com temas sensíveis como dados pessoais, esses tópicos já são parte importante das nossas vidas!
- O conhecimento técnico obtido no curso pode lhe fornecer subsídios para participar das discussões e se posicionar de maneira mais qualificada e apropriada.

O futuro da democracia liberal

- Nesta seção, nosso objetivo é:
 - utilizar algumas ideias da história e sociologia para conjecturar de que maneiras os campos de aprendizado de máquina e ciência de dados podem ser decisivos para a evolução da sociedade no futuro próximo.
- Esta seção é baseada em trabalhos recentes publicados pelo historiador israelense Yuval Noah Harari^{[15][16][17]}.



[15] Yuval Noah Harari. *Sapiens: A brief history of humankind*. Random House, 2014.

[16] Yuval Noah Harari. *Homo Deus - A Brief History of Tomorrow*. Harper, 2017.

[17] Yuval Noah Harari. *21 Lessons for the 21st Century*. Random House, 2018.

Um pouquinho de História...



Por que os seres humanos controlam o planeta?

- É evidente que os seres humanos controlam o planeta inteiro.
- A pergunta é: por quê? Como isso aconteceu?

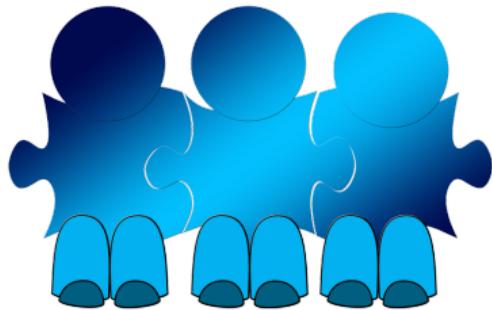
Um pouquinho de História...

Por que os seres humanos controlam o planeta?

- Se você respondeu "*por que somos mais inteligentes*", lembre-se de nossos ancestrais pré-históricos, há 70.000 anos atrás.
- A maioria deles era muito mais inteligente do que nós (individualmente), e mesmo assim a humanidade não controlava o planeta!
- O impacto dos seres humanos no mundo na verdade era insignificante.



Um pouquinho de História...



Por que os seres humanos controlam o planeta?

- O segredo do nosso sucesso está na capacidade de *cooperação*.
- Os seres humanos são os únicos animais capazes de cooperar *em grande número e de forma flexível*.
- Formigas conseguem coperar em grande número, mas não de forma flexível.
Chimpanzés conseguem cooperar de forma flexível, mas não em grande número. Apenas os humanos conseguem os dois!!

Um pouquinho de História...

Por que os seres humanos controlam o planeta?

- Pergunta: por que os seres humanos conseguem cooperar de forma tão eficiente? Como exatamente isso acontece?

Um pouquinho de História...

Por que os seres humanos controlam o planeta?

- Resposta: por conta da nossa imaginação!
- Os seres humanos são os únicos animais capazes de inventar histórias (ficções). Se todos acreditam nelas, a cooperação se torna possível.
- Exemplos de algumas histórias que permitem cooperação em larga escala: Brasil, Estados Unidos, União Soviética, Google, Chevrolet, UFRJ, ONU, direitos humanos, democracia, Código Penal, Supremo Tribunal Federal, Presidência da República, real, dólar (essa última sendo a mais poderosa de todas).
- Os animais vivem em duas realidades: objetiva e subjetiva. Seres humanos criam um novo tipo de realidade: a *realidade inter-subjetiva*.
- Os demais animais usam a comunicação para descrever as realidades objetiva e subjetiva, e não para estendê-la, como nós.

Um pouquinho de História...

Humanismo: a história dominante

- A história dominante dos últimos séculos foi a história do *humanismo*: a crença de que o *Homo sapiens* tem uma natureza sagrada, diferente de todos os demais fenômenos e seres do mundo natural.
- Essa história tem três vertentes principais:
 - 1) humanismo liberal:
 - 2) humanismo socialista:
 - 3) humanismo evolucionário.

| | Humanismo liberal | Humanismo socialista | Humanismo evolucionário |
|-----------------------------------|--|---|--|
| | <i>A espécie Homo sapiens tem uma natureza sagrada, especial em relação a todos os demais fenômenos e seres.</i> | | |
| O que é a humanidade? | É uma característica de cada Homo sapiens individual. | É uma característica coletiva e reside na espécie como um todo. | É uma característica mutável que pode degenerar ou evoluir. |
| Qual o mandamento supremo? | Proteger as liberdades individuais, os direitos humanos, a democracia, o livre arbítrio e o livre mercado. | Proteger a igualdade entre os membros da espécie. | Proteger a humanidade de degenerar em sub-humanos e estimular a evolução para super-humanos. |

Um pouquinho de História...

Humanismo liberal: a história vitoriosa

- **Segunda Guerra Mundial:** confronto entre essas três vertentes do humanismo, com derrota do humanismo evolucionário.
- **Guerra Fria:** confronto entre as duas vertentes restantes, com derrota do humanismo socialista.

Um pouquinho de História...

Humanismo liberal: a história vitoriosa (até quando?)

- Portanto, a história vitoriosa e dominante de trinta anos para cá é o humanismo liberal.
- A grande questão é que a fé nessa história vem diminuindo. Há uma percepção cada vez maior de que ela não é capaz de resolver nossos problemas.
- Provavelmente vivemos um período de transição muito especial, em que a história dominante está prestes a mudar.
- Pergunta mais importante dos dias atuais: *qual história vai substituir o humanismo liberal?*

Ameaças ao humanismo liberal

Inteligência, sim. Consciência, para quê?

- Um dos principais princípios que ameaçam o humanismo liberal nos próximos anos é:

Para as instituições e empresas, a inteligência é essencial, mas a consciência é opcional e muitas vezes contraproducente.

Ameaças ao humanismo liberal

Inteligência, sim. Consciência, para quê?

- A automação do século passado se baseou na *automação de tarefas mecânicas*.
- A automação do século XXI se baseia na *automação do reconhecimento de padrões*.
- Tente pensar em algumas profissões que se baseiam em reconhecimento de padrões.

Ameaças ao humanismo liberal

Inteligência, sim. Consciência, para quê?

- Exemplos: motoristas, contadores, investidores da bolsa, médicos, farmacêuticos, advogados, músicos, pintores...
- Franziu a testa no caso dos músicos ou pintores? Confira [este](#) ou [este](#) conteúdos. E isso é só o começo...
- Perigo: o surgimento de uma classe de pessoas economicamente inúteis!
- Uma das principais perguntas do séc XXI provavelmente será: *o que fazer com essas pessoas?*

Ameaças ao humanismo liberal

A autoridade passa para os algoritmos

- Outro princípio que ameaça o humanismo liberal:

Seres humanos tomam decisões de acordo com mecanismos bioquímicos. Algoritmos artificiais são mais sofisticados, eficientes e podem trabalhar em rede. Portanto, são capazes de tomar melhores decisões.

Ameaças ao humanismo liberal

A autoridade passa para os algoritmos

- Se os algoritmos eletrônicos são capazes de tomar as melhores decisões, por que não deixá-los fazer isso?
- Achou assustador? Pensa que nunca vai acontecer? Então reflita sobre esses casos:
 - sistemas de navegação GPS;
 - sistemas de recomendação;
 - sistemas de busca online (quem passa da primeira página do Google?).
- Há uma ilusão bastante difundida de que as pessoas prezam muito o ato de tomar decisões. Na verdade, as pessoas prezam suas certezas. Decidir perante à incerteza é angustiante e pode causar grande sofrimento.

Ameaças ao humanismo liberal

A autoridade passa para os algoritmos

- Há dois mecanismos principais pelos quais os algoritmos podem aumentar sua capacidade de tomar decisões sobre nós:
 - 1) pela obtenção, em rede, de uma grande quantidade de dados da sociedade como um todo;
 - 2) pelo monitoramento cada vez mais completo do indivíduo por meio de sensores bioquímicos e *gadgets* biônicos.
- Exemplos que já acontecem: detecção de uma epidemia por meio de estatísticas de buscas no Google; monitoramento da velocidade de leitura de diferentes páginas de um livro no Kindle.
- Exemplos que provavelmente acontecerão: detecção de doenças individuais por meio do monitoramento da bioquímica do corpo; detecção de sentimentos e emoções por meio do monitoramento dessa mesma bioquímica.

Ameaças ao humanismo liberal

A autoridade passa para os algoritmos

- Uma vez que os algoritmos passam a saber cada vez mais sobre nós (graças às redes sociais, aos sensores bioquímicos e aos dispositivos biônicos), e sobre a sociedade como um todo (já que trabalham em rede), torna-se cada vez mais confortável deixar as decisões por sua conta.
- Tanto as decisões que seriam tomadas por outros seres humanos (ex: tratamentos médicos) quanto as decisões pessoais (exs: que música ouvir? Quem escolher para governar? Qual faculdade cursar? Com quem se casar?) seriam tomadas de forma muito mais simples e, o mais importante, *com maior probabilidade de acerto*.
- Seria o fim do livre arbítrio e da suprema autoridade do indivíduo para fazer suas escolhas.

Ameaças ao humanismo liberal

A autoridade passa para os algoritmos

- Muitos podem argumentar que, nesse cenário, haveria uma resistência grande a fazermos parte do sistema, em nome de valores como, por exemplo, privacidade.
- Só que, na verdade, já fornecemos nossos dados e privacidade a essas empresas em troca de memes e serviços de e-mail.
- Imagine quando o oferecido na troca for bem mais valioso, como nossa saúde ou bem-estar social?
- Se as coisas continuarem a evoluir nesse passo, chegará um momento em que será impossível se desconectar da rede. Desconexão significará morte. Ex: um mundo em que sensores biométricos e nano-robôs online se integrem ao corpo humano.

Dataísmo - uma nova história dominante

Dataísmo

- O historiador Yuval Noah Harari tem um nome para essa nova possível história dominante, em que a autoridade passa do indivíduo para os algoritmos: *dataísmo* (do inglês *data*, que significa dados).
- No dataísmo, o universo é percebido como um fluxo constante de dados e os seres humanos são elementos nesse fluxo.

Dataísmo - uma nova história dominante

Dataísmo

- Capitalistas liberais acreditam na “mão invisível do mercado”. Dataístas acreditam na “mão invisível do fluxo de dados”.
- O dataísta encara a Quinta Sinfonia de Beethoven, uma bolha no mercado financeiro, um reator de escoamento empistonado e o coronavírus como quatro padrões de fluxo de dados que podem ser analisados utilizando os mesmos conceitos e ferramentas.
- O impacto dessa possível nova história não deve ser subestimado, já que constitui o primeiro valor totalmente original a surgir desde a emergência do humanismo no século XVIII.

Dataísmo - uma nova história dominante

Dataísmo

- Organismos, ecossistemas, sociedades, economias e estruturas políticas podem ser interpretadas como sistemas de aquisição, processamento e análise de dados!
- Quanto mais eficiente o sistema, maior sua vantagem competitiva em relação aos demais.
- Essa visão pode explicar, por exemplo:
 - a evolução biológica pela seleção natural;
 - a vitória do capitalismo sobre o comunismo;
 - a vitória das ditaduras sobre as democracias na maior parte da História;
 - a vitória das democracias sobre as ditaduras nas últimas décadas;
 - declínio da fé nas democracias nos últimos anos!

Dataísmo - uma nova história dominante

Dataísmo

- Diria o dataísta: “Se você experimentou algo, grave. Se gravou, faça upload. Se fez upload, compartilhe”.
- O supremo valor está na conexão ao fluxo de dados!

Dataísmo - uma nova história dominante

Dataísmo

- Muito se discute, principalmente em tempos agitados como os atuais, sobre a possibilidade de ditaduras militares, comunismo, etc, mas será que essa discussão não está se tornando pouco a pouco obsoleta? Será que o mundo está se encaminhando para ser dataísta, sem nem se dar conta?
- Se você acha tudo isso muito louco, pense em como você se sente quando sua conexão à Internet é interrompida à sua revelia. Qual o valor que você atribui à conexão ao fluxo de dados?
- Seria você um dataísta????

Obrigado pela atenção!



@escolapilotopeq
@engepolgrupo